

Music Genre Classification

Pascu Cristian Vlad, Vasile Andrei Valentin, Simionescu Tiberiu
Cosmin, Chitac Marius

12 Februarie 2023

Problema

Avand o melodie in format wav, sa se decida in ce gen muzical s-ar incadra. Formatul wav este util pentru stocarea unui audio bitstream.

Dataset-ul

Dataset-ul (data.csv) este format din 1000 de melodii (100 de melodii per gen muzical si 10 genuri). Genurile muzicale sunt: blues, classical, country, disco, hiphop, jazz, metal, pop, reggae, rock. In dataset se gasesc urmatoarele date referitoare la melodii:

1. tempo: The tempo, or pace, of the music measured in beats per minute (BPM).
2. beats: The number of beats in a musical piece.
3. chroma-stft: Chroma short-time Fourier transform, a representation of the musical harmony.
4. rmse: Root mean square energy, a measure of the power of a musical signal.
5. spectral-centroid: The average frequency of a musical signal.

Dataset-ul

6. spectral-bandwidth: A measure of the spread of frequencies in a musical signal.
7. rolloff: A measure of the frequency below which a certain percentage of the total spectral energy lies.
8. zero-crossing-rate: The rate at which the audio signal crosses the zero axis, a measure of the roughness or noisiness of the sound.
9. mfcc1 to mfcc20: Mel-frequency cepstral coefficients, a representation of the spectral envelope of the music.
10. label: A string label that indicates the type of audio content (e.g. speech, music, silence).

Support vector machine

SVM este un algoritm de invatare supervizat care construiește un model pentru a face previziuni. Gaseste limita optima care separa clasele diferite si foloseste aceasta limita pentru a face preziceri. SVM functioneaza bine atunci cand datele sunt separabile liniar. SVM are o acuratete pentru aceasta problema de 0.732.

K-nearest neighbors

KNN este un algoritm de invatare lent, ceea ce inseamna ca nu construiește un model pentru clasificare. In schimb, isi pastreaza datele de antrenament si le foloseste pentru a face previziuni atunci cand se intalneste un nou punct de date. Previziunea se bazeaza pe clasa majoritara dintre cele k vecini apropiati ai noului punct de date. KNN are o acuratete pentru aceasta problema de 0.656.

Features using Decision Tree

Folosirea unei metode de importanta a caracteristicilor bazate pe un arbore de decizie poate fi utila in clasificarea genului muzical pentru a identifica care caracteristici sunt cele mai importante pentru a determina genul muzical.

Un arbore de decizie este un model de invatare supervizat care se bazeaza pe întrebări succesive despre date pentru a face previziuni. Fiecare nod in arbore reprezinta o întrebare despre date, iar ramurile din nod reprezinta răspunsurile posibile la acea întrebare. In final, fiecare frunza a arborelui reprezintă o clasa sau previziune.

Features using Decision Tree

Folosind acest model, se poate identifica importanța fiecărei caracteristici în luarea deciziilor. De exemplu, dacă o caracteristică apare într-un nod înalt din arbore, aceasta înseamnă că este importantă pentru separarea în clase diferite și, prin urmare, este considerată importantă pentru problema de clasificare.

Cu alte cuvinte, un arbore de decizie poate fi util pentru a identifica caracteristicile cheie ale genului muzical care sunt necesare pentru a face previziuni precise. Acest lucru poate fi util pentru a îmbunătăți modelul sau pentru a înțelege mai bine caracteristicile și proprietățile genului muzical.

Features using Random Forest

Metoda de importanta a caracteristicilor bazata pe Random Forest functioneaza prin crearea mai multor arbori de decizie si prin combinarea rezultatelor acestora. Fiecare arbore din foresta aleatoare este antrenat pe o subsample aleatoriu din datele de antrenare si pe o submultime aleatoare din caracteristici.

După ce se antrenează fiecare arbore, se poate calcula importanta fiecărei caracteristici prin evaluarea contribuției la acuratetea prezicerilor fiecărui arbore. De exemplu, dacă o caracteristică apare în majoritatea arborilor și contribuie semnificativ la acuratetea previziunilor, aceasta poate fi considerată importantă pentru problema de clasificare.

Features using Random Forest

Cu alte cuvinte, folosirea unui Random Forest poate oferi o estimare mai precisă a importanței caracteristicilor în comparație cu folosirea unui singur arbore de decizie, deoarece combină rezultatele mai multor modele antrenate pe diferite subsample-uri aleatoare din date și caracteristici.

Rezultate Random Forest vs Decision Tree

Decision Tree a avut ca rezultat faptul ca mfcc4 influenteaza cel mai mult rezultatul si ca aceasta are o importanta mai mare fata de restul. In aceasta clasificare, chroma-stft a iesit pe locul 3.

Random Forest a avut ca rezultat faptul ca feature-ul chroma-stft a avut cea mai mare importanta, mfcc4 fiind pe locul 3.

Concluzie

În această problemă, obiectivul era clasificarea genului muzical în funcție de un fișier audio în format wav. Am abordat această problemă prin utilizarea a două metode de clasificare, KNN și SVM. Acuratetea obținută prin utilizarea SVM a fost de 0.732, în timp ce acuratetea obținută prin utilizarea KNN a fost de 0.656. De asemenea, am discutat și despre utilizarea metodei de importanță a caracteristicilor bazată pe Random Forest, care poate oferi o estimare mai precisă a importanței caracteristicilor în comparație cu alte metode.